

商业计划书 (BP): Phaser AI - 终结算力暴政的“自由能与规范场”双引擎人工智能

一、 执行摘要 (Executive Summary)

我们的定位：

Phaser AI 并非“又一家大模型公司”，我们致力于打造**全球首个基于“自由能最小化”与“规范场论”底层双支柱的下一代物理-AI融合引擎**。

在算力暴力美学（Scaling Law）遭遇物理墙的当下，我们重构了神经网络的底层运行逻辑，为具身智能、超长程因果推演（如世界模型、供应链风控）以及 AI for Science 提供算力成本仅为当前极小比例、且自带“物理常识”的新一代基座引擎与专用存算架构。

我们的降维打击（为何现在？为何是我们？）：

当前全球“非 Transformer”阵营虽然风起云涌（如以色列的 AI21 Labs 融资3.36亿美金，MIT的 Liquid AI 融资2.5亿美金），但他们分别陷入了“机械缝合”与“浅层平滑”的工程泥潭。中国市场极度渴望拥有自主知识产权的下一代基础架构。

Phaser AI 摒弃了花哨的概念，直击智能的本质，通过**自由能原理（驱动算力自适应）与规范场论（保障几何与逻辑抗扭曲）**，对全球竞品实现了代差级的技术压制。

二、 市场痛点与全球竞对的“致命软肋”

当前的大模型（GPT-4、Qwen 等）被困在纯语言统计学中。为了模拟物理世界并降低能耗，行业内催生了两条“自救”路线，但都存在底层缺陷：

1. 竞对一：AI21 Labs (主打 Jamba 混合架构) —— “机械缝合的科学怪人”

- 他们的做法：**将 Transformer 和 Mamba 强行按固定比例（如 1:7）交替拼接，试图兼顾性能与速度。
- 他们的软肋：**死板的算力分配与流形错位。面对真实的复杂业务流，固定的网络层数无法根据任务难度自适应调配算力。
- Phaser 的降维打击：**基于“自由能 (Free Energy)”的动态算力分配。

Phaser 抛弃了人工拼接。我们引入了认知科学中的“自由能最小化”原理（即大脑总是试图降低意

外/信息熵)。系统会实时感知数据的“认知难度”：

- 遇到平稳简单的任务（自由能低），网络自动坍缩为线性的 Mamba 态，实现极低功耗的快速滑行。
 - 遇到复杂逻辑（自由能高），网络瞬间展开为全局的 Attention 态进行深度思考。
- 这是一种具备真实生命力的算力自组织，而非僵硬的模块拼接。

2. 竞对二：Liquid AI (主打 LFM 液态基础模型) —— “困在一维时间的平滑”

- **他们的做法：**利用常微分方程 (ODE) 构建液态神经网络，使权重随时间平滑演化，实现端侧极快推理。
- **他们的软肋：**缺乏应对空间畸变与极端非线性的能力。面对宏大物理世界（如机器人的非刚性动作、多体博弈）的坐标扭曲，单纯的时间平滑是无力的。
- **Phaser 的降维打击：**“规范场 (Gauge Field)”保障绝对鲁棒性。

我们直接在网络层间植入“规范场算子（即一种动态坐标校准雷达）”。它能在特征传递前，主动抵消掉环境扭曲带来的干扰。这使得 Phaser 在极小的模型体积下，也能实现完美的空间几何泛化，无需像竞品那样堆砌海量的冗余参数去“死记硬背”各种视角变化。

3. 国内市场：生态位极度真空

- 国内的创业明星均是在**应用层**利用美国发明的旧轮子（Transformer 或 扩散模型）去强行拟合物理世界。
- **Phaser 填补了中国在“AI 底层计算公理”上的绝对空白。**我们是第一家真正将物理场论与大模型融合的底层架构公司。

三、Phaser 的物理级大一统：从双支柱到技术繁衍（我们的绝对护城河）

我们不炒作参数规模，我们只回归解决智能的物理本质问题。Phaser 的强大，源于我们将“规范场”与“自由能”在底层数学上实现了泛函层面的完美统一，并由此衍生出系统性解决当前大模型核心瓶颈的统一框架。

（一）底层公理：数学与物理的终极统一

在 Phaser 引擎中，规范场与自由能不是生硬拼接的代码模块，而是统一于一个宏大的“总自由能泛函 (Free Energy Functional)”方程中：

$$F = \int \left[\cdots + \frac{1}{2m} |D_\mu \psi|^2 + \cdots \right] d^D x$$

在这个方程中， D_μ 代表包含了“规范场”补偿的协变导数。

- **物理意义**：网络在追求“自由能最小化（即寻找最优解、降低不确定性）”的过程中，**必须且必定**会通过规范场去抚平数据空间中的“几何扭曲”与“假性混乱（如视角的切换、语序的颠倒）”。
- **工程价值**：规范场负责滤除宇宙中的“几何噪音”，而自由能引擎才能精准感知到世界真正的“逻辑复杂熵”，从而极其精准、吝啬地调配算力。

（二）基石 0.5 衍生：热力学“磁畴” → 统一稀疏性 (MoE) 与低秩性 (LoRA)

- **痛点**：目前大厂为了省算力，被迫使用极其生硬的路由 (MoE) 和外挂的低秩矩阵 (LoRA)，两者在工程上相互割裂且训练极不稳定。
- **深层演化（对称性破缺）**：
我们通过在损失函数中引入热力学正则化，让特征空间发生“自发对称性破缺”。这使得神经元会像物理世界中的磁铁一样，自发结团形成“磁畴 (Magnetic Domains)”。
(商业表述：磁畴的边界就是纯天然的稀疏路由 (MoE)，磁畴的内部就是高度一致的低秩流形 (LoRA)。我们用一个底层机制同时实现了计算与显存的双重压缩，这是大厂靠堆代码永远无法实现的底层优雅。)

（三）基石一衍生：规范场 (Gauge Field) → 赋予模型几何与逻辑免疫力

- **痛点**：传统模型是“几何盲”，遇到旋转或局部畸变就瘫痪，只能靠喂入天量增强数据来弥补。
- **深层演化（高阶规范场应用）**：
从基础的几何对齐出发，我们进一步引入了**高阶非线性关联场（非对易规范场）**。当处理深层语言或因果时，这种高阶场能产生极强的特征耦合力，将复杂的逻辑链条死死咬合，使其在长程推演中绝不断裂。
(商业表述：赋予大模型真正的零样本泛化能力，在端侧世界模型应用中，可剪裁掉高达 80% 的无效冗余参数。)

（四）基石二衍生：自由能 (Free Energy) → 实现“极致的端侧算力抠门”与长程稳态

- **痛点**：传统 Transformer 不论任务多简单都要跑满全功率（导致端侧设备发热），且超长序列极易导致显存爆炸与上下文遗忘。

- **深层演化（相变与高维拓扑映射）：**

- i. **连续相变：**基于自由能感知，网络在 $O(N)$ 的线性态（快速滑行）与 $O(N^2)$ 的全局纠缠态（深度思考）间自发相变。
- ii. **高维空间映射：**在需要进行极端复杂推演（高自由能）时，系统启动高维负曲率空间映射机制，将线性序列指数级压缩至非欧几何空间中进行“慢思考”寻址。
- iii. **稳态拓扑记忆：**我们用生成“稳态拓扑守恒结构”的方式保存关键变量，实现了显存占用的常量化，免疫一切梯度耗散。
(商业表述：将长视频、长因果推演的运行时显存占用死死压缩，实现了端侧极致低功耗与不遗忘的推演。)

四、 商业化路径与非对称落地战略

避开与巨头在“写诗作画”和通用大模型 (AGI) 上的烧钱内卷，直击需要“端侧极致低功耗”与“严密物理推演”的高净值深水区。

Phase 1: 降维打击的“特种兵”入场 (第 0 - 18 个月)

- **核心产品：**Phaser-Edge 边缘推演模型 & 专有 API。
- **切入场景：**
 - **全球供应链极长因果图风控：**解决大厂模型在超长逻辑推演中的“灾难性遗忘”问题，精准刻画宏观博弈。
 - **低空经济与具身智能防撞大脑：**利用规范场的“几何免疫”特性，为无人机蜂群提供极低功耗、免海量数据训练的局部物理防撞引擎。
- **里程碑：**在一个严苛的长序列因果推理任务或真实物理碰撞仿真上，用仅有不到 1B 参数的 Phaser 端侧模型，公开击败百亿参数的传统 Transformer，确立技术神坛地位。

Phase 2: “具身智能”的终极大脑底座 (第 2 - 3 年)

- **商业模式：**将搭载“规范场与自由能”双引擎的微缩模型，以软件授权或软硬一体模组形式，卖给大疆、特斯拉、宇树等机器人厂商。成为他们“免海量数据训练、低功耗、不迷路”的标准小脑中枢。

Phase 3: 软硬协同的“AI时代的ARM+NVIDIA” (第 4 - 6 年)

- **终局形态：**设计并发布专门针对“规范场校准计算”和“自由能动态路由”的 **Phaser 加速卡 (PPU)**。
- 搭载 PPU 的端侧和云端设备，其平均功耗将降至当前 GPU 架构的十分之一，完成从算法到算力底层的终极闭环垄断。

五、核心团队与融资规划 (Team & Funding)

1. 极简“特种部队”阵型 (The Elite Squad)

我们拒绝“堆人头”的旧大厂模式。在早期阶段，我们采用最具资本效率的“1+2+N”阵型，将核心技术灵魂与商业闭环牢牢掌握在极少数精英手中：

- **创始人 (CEO & 首席科学家)：**
 - 作为“物理 AI 统一场论”的提出者与架构设计师，掌控最底层的数学推导（规范场、双曲映射、李代数低秩更新）与算法核心方向。
 - 负责公司整体战略、融资以及超高客单价标杆客户的破冰。
- **AI Infra 负责人 (底层基建大牛)：**
 - **职责：**将复杂的物理流形公式转化为可在 GPU 上极其高效运行的 CUDA 算子。负责底层计算性能的极限压榨，确保 Holo-RAG 在极低算力下的延迟与吞吐量碾压传统数据库。
- **大客户销售合伙人 (BD / 搞钱机器)：**
 - **职责：**自带金融、泛法律或医疗等高净值行业资源。不讲虚的 AI 概念，只拿 Holo-RAG “免知识图谱抽取、精准树状因果推理”的降维打击卖点，在头 12 个月内死磕拿下 2-3 个百万级 B 端大单，实现公司早期造血。
- **高潜力算法/工程实习生 (N 名)：**
 - **职责：**由国内顶尖高校（清北复交等）的优秀硕博生组成，负责上层业务代码编写、数据清洗、Demo 前端搭建等具体执行工作。极低的人力成本，极高的迭代速度。

2. 融资需求与算力奇袭策略：400万人民币 / 18个月 (天使轮)

我们不寻求动辄数千万美金的“算力军备竞赛”式融资。传统大厂训练一个 8B 模型动辄需要 300-500 万人民币的纯算力成本，是因为他们采用了极其低效的“随机初始化炼丹法”。

我们寻求 **400万人民币（出让 10%-15% 股份）** 的天使轮资金，依靠我们独有的“物理结构嫁接与自适应降维”策略，以极低的成本打透工程闭环并实现商业造血。

资金极客级分配方案：

1. 算力与模型训练 (45%，约 180万) —— “物理点化”与退火训练：

- **算力奇袭：**我们**绝不从零预训练**。我们将提取顶尖开源模型（如 Qwen-7B）的成熟权重，通过“知识保持映射”等价嫁接到我们的 Phaser 物理网络层上（起点即是别人的终点）。
- **平滑退火策略 (Annealing Gating)：**在嫁接初期，我们的自适应门控将 Attention（高功耗全连接态）比例设为 100%，以完美保持原模型的智能水平。随后利用这笔极为充沛的算力预算，进行高强度的“物理强化微调 (Continual Pre-training)”，喂入海量高熵因果数据，**随着训**

练的推进，逐渐降低门控阈值，让系统自发地将大部分简单计算退火至 $O(N)$ 的 Mamba 态，最终实现不降智但功耗暴降的相变。

2. **核心团队薪酬 (40%，约 160万)**：通过高额期权绑定核心大牛，将现金薪酬压至极致底线（160 万），保障核心突击队 18 个月的绝对稳定，把挤出来的每一分钱都投入到模型训练算力中。
3. **极简运营与专利护城河 (15%，约 60万)**：
 - **专利护城河 (约 20万)**：集中资源在全球核心市场申请 1-2 项最底层的机制专利（如李代数低秩更新、RAG 双曲算子映射），放弃漫天撒网。
 - **企业日常运营 (约 40万)**：覆盖 18 个月的共享办公空间租赁、实习生津贴、基础差旅等费用，保持极度克制的“车库创业”状态。

3. 18 个月“血战”里程碑 (Milestones)

- **Month 1 - 4 (数学原型与算子闭环)**：完成核心双曲算子与 Embedding 改造，在内部“复杂逻辑推理数据集”上证明准确率远超传统 Cosine RAG。
- **Month 5 - 9 (打造可售卖的 B 端利器)**：针对超长财务审计或法律案宗，组装出“Holo-RAG 知识引擎”商业 Demo。签下首个 B 端“标杆型种子客户”，实现几十万级早期验证收入。
- **Month 10 - 18 (自我造血与开启 A 轮)**：Holo-RAG 引擎标准化为 Enterprise API。拿下 2-3 个百万级订单，实现现金流打平。带着真实 B 端收入和客户证明的“碾压级准确率”，以数亿估值开启 Series A 轮融资，正式研发百亿参数级的“原生物理 AI 基础模型”。

六、为什么我们能赢？（愿景与格局）

在这场智能工业革命中，如果 Transformer 是一把依赖暴力算力砸开大门的重锤，那么 Phaser 就是一把基于最基础物理公理的精密手术刀。

剥离掉一切虚幻的词藻，我们用“规范场”解决了空间和逻辑的稳定性，用“自由能”解决了算力和时间的经济性。

Phaser AI，用最简洁的物理法则，重塑人工智能的计算底座。